



Proyecto Integrador: Análisis de Usuarios de Streaming

Minería de Datos 1 — FCEyT — UNSE

Integrantes:

Carlos Isaías Cazazola Ríos

Julio 2026

1. Introducción

El presente informe documenta el desarrollo de un proyecto integrador orientado al análisis de datos de usuarios de una plataforma de streaming regional. El objetivo es construir un flujo de trabajo reproducible y trazable que abarque desde la inspección inicial de los datos crudos hasta la síntesis de hallazgos mediante técnicas de reducción de dimensionalidad, sustentando cada decisión de limpieza en evidencia cuantitativa.

El dataset contiene 8.160 registros de usuarios, con variables demográficas (edad, país), de consumo (plan de suscripción, minutos de visualización mensual, género favorito), de comportamiento (fecha de último ingreso) y de soporte técnico (tickets abiertos).

2. Metodología

2.1 Inspección inicial

Se realizó una carga y diagnóstico preliminar del dataset original (formato JSON), identificando el tipo de dato de cada columna, la presencia de valores nulos y la existencia de inconsistencias categóricas y numéricas que requerían tratamiento antes de cualquier análisis.

2.2 Calidad y limpieza de datos

La preparación del dataset se ejecutó como un pipeline de pasos secuenciales, cada uno registrado y auditado en términos de filas afectadas, nulos remanentes y porcentaje de retención de datos. La siguiente tabla resume las transformaciones aplicadas:

Paso	Descripción	Filas	Nulos	Retención (%)
0. Estado Inicial	Carga del dataset original sin modificaciones	8160	753	100.0
1. Limpieza de Tipeo	Estandarización de country (Title Case) y mapeo de abreviaturas	8160	560	100.0
2. Tipificación Temporal	Conversión de last_login_date a datetime	8160	1009	100.0
2.1 Fechas Futuras	Imputación de 15 fechas posteriores al 2026-07-02 por la mediana	8160	1009	100.0
3. Outliers Tickets	Imputación de tickets fuera de 0-20 por mediana robusta	8160	1009	100.0
4.1 Outliers Edad	Imputación del valor atípico (150 y edades negativas) por moda robusta	8160	753	100.0
4.1.2 Edad Cero	Imputación de 24 registros con edad 0 por la moda	8160	753	100.0
4.2 Outliers Consumo	Imputación de valores >2000 o <0 en monthly_watch_time_mins por la media	8160	753	100.0
5. NaNs Consumo	Sustitución de faltantes en monthly_watch_time_mins por la mediana	8160	560	100.0
5.2 Imputación Fecha	Sustitución de nulos en last_login_date por la mediana	8160	240	100.0

Adicionalmente, se unificaron las variantes de subscription_plan (Basic, Std, Standard, Premiun y combinaciones de mayúsculas/minúsculas) en tres categorías consistentes: Básico, Estándar y Premium. Esta consolidación evitó la fragmentación artificial de segmentos en los análisis posteriores.

Justificación del tratamiento de outliers: mantener el registro de 150 años en la variable edad habría distorsionado artificialmente la media y sobredimensionado la varianza global, contaminando además el cálculo de las componentes principales del PCA con una fuente de variabilidad espuria.

2.3 Dataset final

Tras la limpieza, el dataset queda compuesto por 8.160 filas y 8 columnas, sin outliers biológicamente imposibles y con categorías consistentes:

Plan de Suscripción	Cantidad de usuarios
Básico	3.664
Estándar	2.875
Premium	1.621

3. Análisis Exploratorio de Datos (EDA)

3.1 Distribuciones univariadas

- Edad: la población se concentra en un rango adulto-joven de entre 25 y 40 años.
- País: distribución geográfica regional equilibrada entre Argentina, Brasil, Chile, Colombia, México, Perú y Uruguay, tras consolidar los errores de tipeo.

3.2 Relaciones bivariadas

- Plan de suscripción vs. consumo mensual: los planes Premium y Estándar registran medianas de minutos de visualización marcadamente superiores al plan Básico.
- Edad vs. tickets de soporte: no se observa correlación lineal; las incidencias técnicas ocurren de forma independiente a la edad del usuario.

3.3 Análisis multivariado

Al cruzar edad, consumo mensual y plan de suscripción se observa una clara estratificación horizontal: el factor determinante del nivel de consumo es el plan contratado, operando de manera independiente a la edad cronológica del usuario.

4. Análisis de Componentes Principales (PCA)

Previo a la aplicación del algoritmo, se realizó un escalamiento obligatorio mediante Z-score (StandardScaler) sobre las variables numéricas continuas (age, monthly_watch_time_mins, customer_support_tickets), condición no negociable para neutralizar las diferencias de magnitud entre minutos de consumo y unidades de tickets.

4.1 Matriz de loadings

Variable	CP1	CP2	CP3
age	0.718	0.263	0.644
monthly_watch_time_mins	0.058	0.900	-0.432
customer_support_tickets	0.693	-0.347	-0.632

4.2 Interpretación de componentes

CP1 (Perfil de Madurez y Asistencia): captura conjuntamente la variabilidad asociada a la edad y a los tickets técnicos abiertos (loadings altos y positivos de 0.718 y 0.693), definiendo un perfil de usuarios maduros que demandan mayor asistencia operativa.

CP2 (Eje de Intensidad de Consumo): dominada casi en su totalidad por monthly_watch_time_mins (loading de 0.900), aislando el volumen neto de reproducción como un vector de segmentación independiente.

La combinación de las dos primeras componentes logra retener la estructura esencial de la información original, permitiendo una proyección multivariada óptima sin pérdidas críticas de varianza.

5. Conclusiones

5.1 Hallazgos principales

El comportamiento de consumo en minutos mensuales está directamente condicionado por la estructura del plan de suscripción contratado, y no por variables demográficas tradicionales como la edad, que no muestra correlación lineal ni agrupamientos estadísticamente significativos respecto al volumen de visualización o a la tasa de incidencias de soporte técnico.

5.2 Impacto de la limpieza de datos

La etapa de inspección y preparación consciente fue crítica para el éxito del proyecto. De no haberse tratado las anomalías detectadas (variantes categóricas inconsistentes, edad de 150 años, 99 tickets de soporte), las conclusiones de negocio y los modelos matemáticos habrían sufrido sesgos severos, incluyendo una CP1 contaminada por variabilidad geométrica artificial en lugar de patrones reales de comportamiento.

5.3 Limitaciones del proyecto

El alcance de las conclusiones está condicionado por la naturaleza transversal del dataset y el número limitado de variables operativas disponibles. Al tratarse de una captura estática y no contar con historial temporal, logs de navegación por sesión o series de tiempo, no es factible evaluar la causalidad directa de la baja de usuarios (churn) ni las variaciones estacionales de consumo.

5.4 Mejoras futuras propuestas

- Incorporar métricas de retención: costo de adquisición del cliente (CAC), tasa de cancelación (churn rate) e interacciones de soporte clasificadas por motivo técnico/administrativo.
- Automatizar reglas de calidad de datos (expresiones regulares o esquemas de validación) en la interfaz de registro, para impedir en origen el ingreso de cadenas inconsistentes o edades biológicamente inverosímiles.

6. Aplicación y repositorio

Los hallazgos de este informe se encuentran también disponibles en una aplicación interactiva desarrollada en Streamlit, que permite explorar el dataset, las visualizaciones del EDA y los resultados del PCA de forma dinámica.

Repositorio: [Github](#)